

Título - Estilo de artigo do trabalho de conclusão de curso da FCI

Danilo Tomas Tanganelli¹, Igor Bragança^{1,2}, Lucas Lucinio Cristovam^{1,2,3}

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

²Programa de pós-graduação em Computação Aplicada – Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

```
{danilo.tanganelli, lucas.cristovam, igorbragancatoledo.silva  
}@mackenzie.com.br
```

Resumo. *A proliferação de mensagens indesejadas (spam) em aplicativos de mensageria instantânea, especialmente o WhatsApp, representa um crescente problema social e de segurança digital no Brasil. Este trabalho propõe o desenvolvimento de um modelo de classificação automática de spam utilizando técnicas de Machine Learning, com base em um dataset original coletado e rotulado pelo próprio grupo. A abordagem contempla o pré-processamento de textos em português, extração de características via TF-IDF e Bag of Words, e o treinamento de classificadores como Naive Bayes, Regressão Logística e Random Forest utilizando a biblioteca scikit-learn. Espera-se alcançar acurácia superior a 90% na identificação de mensagens spam, contribuindo para a proteção de usuários vulneráveis e para o desenvolvimento de filtros inteligentes adaptados ao idioma e ao contexto cultural brasileiro. Aspectos éticos, privacidade de dados e responsabilidade no desenvolvimento de soluções de IA são discutidos de forma integrada à proposta. O trabalho está estruturado em seis seções: introdução, descrição do problema, ética em IA, dataset e análise exploratória, metodologia e resultados esperados, e referências.*

Palavras-chave: *spam; WhatsApp; classificação de texto; machine learning; scikit-learn; processamento de linguagem natural.*

Abstract. *The proliferation of unsolicited messages (spam) in instant messaging apps, especially WhatsApp, represents a growing social and digital security problem in Brazil. This paper proposes the development of an automatic spam classification model using Machine Learning techniques, based on an original dataset collected and labeled by the group itself. The approach includes text preprocessing in Brazilian Portuguese, feature extraction using TF-IDF and Bag of Words, and the training of classifiers such as Naive Bayes, Logistic Regression, and Random Forest using the scikit-learn library. The model is expected to achieve accuracy above 90% in identifying spam messages, contributing to the protection of vulnerable users and to the development of intelligent filters adapted to the Brazilian language and cultural context.*

Keywords: *spam; WhatsApp; text classification; machine learning; scikit-learn; natural language processing.*

1. Introdução

O WhatsApp é o aplicativo de mensageria mais utilizado no Brasil, com mais de 147 milhões de usuários ativos, correspondendo a aproximadamente 99% dos smartphones brasileiros (STATISTA, 2024). Essa penetração massiva transformou a plataforma em canal estratégico para comunicação pessoal, comercial e institucional. Contudo, essa mesma ubiquidade a tornou um vetor fértil para a disseminação de spam, phishing, golpes financeiros e desinformação.

Diferentemente do spam em e-mail, que conta com décadas de pesquisa e ferramentas consolidadas, o spam em aplicativos de mensageria instantânea ainda é um campo emergente, especialmente para idiomas distintos do inglês. Mensagens spam no WhatsApp vão desde ofertas comerciais não solicitadas até tentativas de fraude sofisticadas, como falsas promoções de varejistas conhecidos e golpes do PIX, impactando diretamente a segurança financeira de milhões de brasileiros.

Nesse cenário, a aplicação de técnicas de Inteligência Artificial, especificamente de classificação de texto por Machine Learning, surge como uma abordagem promissora para a detecção automatizada e eficiente dessas mensagens indesejadas, contribuindo para a proteção de usuários e para a higiene digital nas redes de comunicação.

A justificativa para este projeto reside em três dimensões principais. Primeiramente, na dimensão social: golpes via WhatsApp causaram prejuízos de mais de R\$ 2,5 bilhões aos brasileiros em 2023, segundo dados do Banco Central e da Febraban (FEBRABAN, 2024). Em segundo lugar, na dimensão técnica: a maioria dos modelos de detecção de spam disponíveis na literatura foi desenvolvida para o inglês, carecendo de adaptação ao português brasileiro, com suas especificidades linguísticas e gírias regionais. Por fim, na dimensão acadêmica: o problema permite aplicar de forma integrada os conceitos centrais da disciplina de Inteligência Artificial, como pré-processamento de linguagem natural, extração de características e avaliação comparativa de classificadores.

O objetivo geral deste projeto é desenvolver e avaliar um modelo de Machine Learning capaz de classificar automaticamente mensagens de WhatsApp em português como spam ou não spam (ham), utilizando técnicas de Processamento de Linguagem Natural e classificação supervisionada.

Os objetivos específicos são:

- Construir um dataset experimental de mensagens em português classificadas manualmente como spam e ham;

- Realizar análise exploratória dos dados para identificar padrões linguísticos característicos de mensagens spam;

- Aplicar técnicas de pré-processamento de texto como tokenização, remoção de stopwords e lematização em português;

- Extrair características textuais utilizando Bag of Words e TF-IDF;

Treinar e comparar os classificadores Naive Bayes Multinomial, Regressão Logística e Random Forest;

Avaliar os modelos por meio das métricas de acurácia, precisão, recall e F1-score, com validação cruzada k-fold (k=10).

Optamos pela Opção Framework, empregando a biblioteca scikit-learn para o desenvolvimento do modelo de classificação. A escolha se justifica pela maturidade da ferramenta, pela ampla documentação disponível e pela adequação ao problema de classificação de texto proposto. Complementarmente, serão utilizadas as bibliotecas NLTK e spaCy para processamento de linguagem natural em português, e pandas e matplotlib para análise e visualização dos dados.

2. Referencial Teórico

O problema de pesquisa central é: é possível treinar um classificador de Machine Learning capaz de distinguir automaticamente mensagens spam de mensagens legítimas (ham) em português brasileiro, com desempenho suficiente para uso prático em filtros de aplicativos de mensageria?

Do ponto de vista computacional, trata-se de um problema de classificação binária (spam = 1, ham = 0) aplicado a dados textuais não estruturados. Os principais desafios técnicos incluem: (i) a naturalidade da linguagem coloquial brasileira, rica em abreviações, emojis e gírias; (ii) o desequilíbrio de classes, pois mensagens spam tendem a ser menos frequentes em datasets naturais; (iii) a presença de URLs, números de telefone e padrões financeiros específicos, como chaves PIX, que são indicadores relevantes de mensagens maliciosas.

O projeto busca preencher uma lacuna de pesquisa identificada: a escassez de datasets e modelos de detecção de spam especificamente voltados para o português brasileiro no contexto de aplicativos de mensageria. Modelos treinados em inglês ou mesmo em português europeu apresentam desempenho degradado quando aplicados ao português brasileiro informal, conforme evidenciado em estudos recentes de processamento de linguagem natural para línguas de baixo recurso (SOUZA; NOGUEIRA; LOTUFO, 2020).

3. Metodologia

O desenvolvimento de sistemas de IA para classificação de mensagens impõe responsabilidades éticas significativas que foram consideradas desde a concepção deste projeto. Quatro dimensões éticas centrais foram identificadas e tratadas na proposta.

O dataset será coletado exclusivamente com o consentimento informado e explícito dos participantes, respeitando os princípios da Lei Geral de Proteção de Dados Pessoais (LGPD — Lei n.º 13.709/2018). Nenhum dado de identificação pessoal, como nome, número de telefone ou foto de perfil, será armazenado. As mensagens serão anonimizadas antes de integrarem o corpus de treinamento, e os arquivos de exportação do WhatsApp serão processados localmente, sem transmissão para servidores externos.

Reconhece-se que modelos de classificação de texto podem incorporar vieses presentes nos dados de treinamento, potencialmente discriminando determinados grupos sociais, regiões geográficas ou estilos de comunicação. Para mitigar esse risco, o dataset buscará representar a diversidade regional e sociolinguística do português brasileiro. A avaliação do modelo incluirá análise de falsos positivos, identificando se determinados grupos de mensagens legítimas são sistematicamente classificados como spam.

O grupo compromete-se com a transparência do processo: o código-fonte, o dataset anonimizado e os resultados serão disponibilizados publicamente no GitHub. Os modelos escolhidos, Naive Bayes e Regressão Logística, possuem grau de explicabilidade superior a modelos de caixa-preta, permitindo a inspeção das características mais relevantes para a classificação por meio de análise dos coeficientes e dos termos mais discriminativos.

O modelo desenvolvido destina-se exclusivamente a fins acadêmicos e de proteção de usuários. O grupo reconhece que nenhum classificador automatizado é perfeito e que a implementação em ambientes de produção exigiria validação adicional e supervisão humana. Além disso, o modelo não deverá ser utilizado para censura de conteúdo ou vigilância de comunicações privadas sem consentimento, em conformidade com o Marco Civil da Internet (Lei n.º 12.965/2014).

O dataset será construído a partir de duas fontes complementares. A primeira consiste em mensagens coletadas pelos integrantes do grupo por meio da funcionalidade de exportação de conversas do WhatsApp, com consentimento explícito dos participantes e devida anonimização. A segunda fonte é o corpus público SMS Spam Collection Dataset (ALMEIDA; HIDALGO, 2012), disponível no repositório UCI Machine Learning Repository, que será traduzido e contextualizado para o português brasileiro.

O dataset utilizado no projeto foi construído em formato CSV contendo mensagens em português classificadas manualmente como spam ou ham. Cada registro possui dois campos: o texto da mensagem e o respectivo rótulo binário.

Para validação inicial da proposta, foi utilizado um conjunto reduzido de mensagens representativas, permitindo implementar e validar o pipeline completo de pré-processamento textual, vetorização, treinamento e avaliação dos modelos de Machine Learning. A análise exploratória será conduzida em Python utilizando as bibliotecas pandas, matplotlib e wordcloud. As investigações previstas incluem: (i) distribuição do comprimento das mensagens por classe (spam vs. ham); (ii) frequência das palavras mais comuns em cada classe, apresentada em nuvens de palavras; (iii) presença de URLs, números de telefone e valores monetários; e (iv) distribuição de emojis e pontos de exclamação, que são indicadores clássicos de mensagens spam.

A análise exploratória permitiu identificar padrões linguísticos presentes nas mensagens classificadas como spam, incluindo termos promocionais como “promoção”, “ganhou”, “PIX”, “urgente” e “clique”.

Também foi observada tendência de mensagens spam apresentarem maior quantidade de caracteres e chamadas de ação em comparação às mensagens legítimas. O pipeline de pré-processamento será implementado em Python e contemplará as seguintes etapas:

- Normalização: conversão para letras minúsculas, remoção de acentuação e caracteres especiais não relevantes;
- Tokenização: segmentação do texto em tokens utilizando NLTK com o tokenizador para português;
- Remoção de stopwords: eliminação de palavras funcionais usando a lista de stopwords do NLTK para português, com adição de termos específicos do domínio;
- Lematização: redução das palavras à forma canônica utilizando o modelo `pt_core_news_sm` do spaCy;
- Extração de características: vetorização por Bag of Words (CountVectorizer) e TF-IDF (TfidfVectorizer), com n-grams de 1 e 2 palavras;
- Divisão do dataset: 80% para treinamento e 20% para teste, com estratificação por classe usando `train_test_split` do scikit-learn.

A pesquisa tem natureza quantitativa e experimental, seguindo o paradigma de Machine Learning supervisionado. A metodologia adotada é baseada no processo CRISP-DM (Cross-Industry Standard Process for Data Mining), que estrutura o desenvolvimento em fases iterativas: compreensão do negócio, compreensão dos dados, preparação dos dados, modelagem, avaliação e implantação (WIRTH; HIPPE, 2000). Essa abordagem garante rastreabilidade e reprodutibilidade do experimento.

Os seguintes algoritmos de classificação serão treinados e comparados:

- Naive Bayes Multinomial (MultinomialNB): classificador probabilístico clássico e amplamente utilizado em detecção de spam de e-mail, serve como baseline do projeto;
- Regressão Logística (LogisticRegression): modelo linear discriminativo robusto para classificação de texto, com boa interpretabilidade dos coeficientes;
- Random Forest (RandomForestClassifier): ensemble de árvores de decisão que captura interações não lineares entre características, servindo como modelo mais complexo do conjunto.

Para cada algoritmo, serão exploradas combinações com os dois métodos de vetorização (BoW e TF-IDF), resultando em seis configurações de modelo. Os modelos

foram treinados e avaliados utilizando as ferramentas de classificação disponíveis na biblioteca scikit-learn, permitindo comparar o desempenho dos algoritmos aplicados ao dataset experimental.

A avaliação do desempenho de cada modelo será realizada com as seguintes métricas:

- Acurácia (accuracy): proporção de classificações corretas sobre o total;
- Precisão (precision): proporção de verdadeiros positivos entre os classificados como spam;
- Revocação / Recall: proporção de mensagens spam corretamente identificadas;
- F1-Score: média harmônica entre precisão e recall, métrica central para datasets com possível desequilíbrio de classes;
- Curva ROC e AUC: avaliação da capacidade discriminativa do modelo em diferentes limiares de classificação;
- Matriz de confusão: análise qualitativa dos tipos de erro (falsos positivos e falsos negativos).

5. Conclusão

Os resultados obtidos demonstraram a viabilidade da utilização de técnicas de Machine Learning para classificação automática de mensagens spam em português brasileiro.

Foram implementadas todas as etapas do pipeline de classificação textual, incluindo pré-processamento, vetorização, treinamento e avaliação dos modelos Naive Bayes Multinomial, Regressão Logística e Random Forest.

Entre os modelos avaliados, o Random Forest apresentou o melhor desempenho experimental no conjunto de teste utilizado. Com base na literatura de detecção de spam em inglês, a hipótese é que a Regressão Logística com vetorização TF-IDF apresentará o melhor desempenho geral, enquanto o Naive Bayes Multinomial servirá como baseline competitivo com custo computacional baixo (ALMEIDA; HIDALGO, 2012).

Como artefato prático do projeto, foi desenvolvido um notebook Python contendo o pipeline completo de processamento textual, treinamento dos modelos e classificação automática de mensagens spam e ham.

O código-fonte e o dataset experimental foram disponibilizados em repositório GitHub para fins acadêmicos.

6. Referências bibliográficas

ALMEIDA, T. A.; HIDALGO, J. M. G. Contributions to the study of SMS spam filtering: new collection and results. In: *Proceedings of the 2012 ACM Symposium on Document Engineering*, p. 259–262, Paris, 2012.

BRASIL. *Lei n.º 12.965, de 23 de abril de 2014*. Marco Civil da Internet. Brasília: Diário Oficial da União, 2014.

BRASIL. *Lei n.º 13.709, de 14 de agosto de 2018*. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília: Diário Oficial da União, 2018.

FEBRABAN — Federação Brasileira de Bancos. *Pesquisa FEBRABAN de Tecnologia Bancária 2024*. São Paulo: FEBRABAN, 2024. Disponível em: <https://febraban.org.br>. Acesso em: 10 mar. 2025.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

RUSSELL, S.; NORVIG, P. *Inteligência Artificial*. Rio de Janeiro: LTC, 2021.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT Models for Brazilian Portuguese. In: *9th Brazilian Conference on Intelligent Systems (BRACIS)*, 2020.

STATISTA. *WhatsApp user penetration in Brazil 2024*. Statista Research Department, 2024. Disponível em: <https://statista.com>. Acesso em: 15 mar. 2025.

WIRTH, R.; HIPPE, J. CRISP-DM: Towards a standard process model for data mining. In: *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, p. 29–39, 2000.